

MaskedBiMamba：改进模型的数学原理、实现过程与实验效果

数学推导 实现机制 实验解析

目录

1. 我们究竟改进了什么	4
1.1 一句话定义模型	4
1.2 两条比较关系要分清	4
1.3 改动、动机和证据之间的对应	4
2. 从视频到数学输入	5
2.1 任务、窗口与符号	5
2.2 时间采样不是“随便收集 30 帧”	5
2.3 保留哪些关节	6
2.4 逐帧归一化：为什么做，又丢失了什么	6
2.5 构造姿态向量与质量向量	6
3. 为什么不能只做单帧或简单时序分类	7
3.1 单帧姿态存在动作歧义	7
3.2 TCN 与 TCNTE 在做什么	7
3.3 从 UniMamba 到完整模型的动机	7
4. 改动一：帧遮蔽训练	7
4.1 实际遮蔽了什么	7
4.2 为什么可以帮助应对缺帧	8
4.3 遮蔽后还会发生什么	8
5. 改动二：用时间自注意力显式比较帧	8
5.1 从相似性到加权信息聚合	8
5.2 为什么要除以根号维度	9
5.3 多头融合、残差与归一化	9
5.4 注意力与 Mamba 为什么同时保留	9
6. 先推导 Mamba 的状态空间原理	10
6.1 状态为什么有用	10
6.2 从微分方程到离散递推	10
6.3 从固定系统到选择性系统	10
6.4 “选择”怎样体现在公式里	11
6.5 展开选择性递推，看到与固定卷积的区别	11
7. Mamba 块在代码中怎样完整计算	11
7.1 投影为内容支路与门控支路	11
7.2 用短卷积组织邻近时间信息	12
7.3 从当前特征生成选择参数	12
7.4 扫描、门控与输出投影	12
8. 改动三：双向编码与时间对齐	12
8.1 为什么添加反向分支	12
8.2 两个方向怎样计算	13
8.3 为什么反向输出必须翻回来	13
8.4 对在线检测意味着什么	13
9. 改动四：质量加权池化	13
9.1 平均池化的问题	13
9.2 实际质量门控网络	14
9.3 权重如何被训练出来	14
9.4 为什么它有时不能改善干净数据	14
10. 分类头与训练目标	15
10.1 从 64 维窗口表示得到概率	15
10.2 为什么使用类别加权	15
10.3 从交叉熵到 focal loss	15
10.4 如果想进一步理解梯度	15

10.5 实际训练设置	16
11. 把所有步骤接成一次完整前向传播	16
11.1 张量尺寸对照	16
11.2 与实现一致的简化伪代码	16
12. 计算代价：哪些部分是线性的，哪些不是	17
13. 实验怎样判断“改了以后是否有效”	17
13.1 本文采用哪一组实验	17
13.2 窗口标签怎样生成	17
13.3 窗口、视频与事件指标分别回答什么	18
13.4 均值、标准差与百分点	18
14. 主实验：得到的是性能取舍，而非全面领先	19
14.1 未加额外测试扰动的主结果	19
14.2 与 TCNTE 相比具体变化了什么	19
14.3 与最强干净数据基线相比	19
15. 消融实验：每一个模块是否都值得保留	19
15.1 去掉一个模块后会怎样	19
15.2 为什么 15% 不是已经证明的最佳比例	20
15.3 消融目前能够回答与尚不能回答的问题	20
16. 鲁棒性与跨数据集：最明确的收益在哪里	21
16.1 当前评价与历史条件的边界	21
16.2 主数据上的有效扰动结果	21
16.3 用降幅衡量缺帧稳定性	21
16.4 为什么不能推广成“对所有遮挡都鲁棒”	22
16.5 Le2i 外部数据上是否也有缺帧优势	22
16.6 为什么外部视频 F1 接近 0.83 仍要看误报	22
17. 从训练模型到树莓派：已经实现了什么	22
17.1 为什么需要可移植扫描实现	22
17.2 当前部署已修复早期输入语义差异	22
17.3 导出一致性检查证明到哪一步	23
17.4 设备测试怎样解释	23
17.5 固定确认规则回放	23
17.6 当前工作台和服务验收	23
18. 怎样准确概括改进及下一步验证	24
18.1 可以用于技术报告的完整表述	24
18.2 对“为什么这样改”的简明回答	24
18.3 最值得补做的验证	25
附录 A. 常见误解速查	25
附录 B. 公式与代码定位	26
附录 C. 证据索引与复核范围	26
附录 D. 用一个可手算的例子串起状态、双向与池化	27
历史补充：已排除的空间缺失条件	28

中文技术文档·FallGuard 骨架时序跌倒检测项目·更新：2026 年 10 月 7 日

本文面向需要理解、讲解或继续修改模型的项目成员。阅读顺序是：先建立输入和基线的数学定义，再推导每个改动，最后用实验判断这些改动是否有效。本文依据项目实际实现与 2026 年 9 月 18 日主实验归档编写；9 月 16 日模型及后续设备测试另作说明，不混合为同一组结果。本文是技术解释文档，不对原有模型、权重或实验记录作修改。

1. 我们究竟改进了什么

1.1 一句话定义模型

MaskedBiMamba 是一个以人体骨架序列为输入的二分类模型：它将关节坐标与置信度编码为时间序列，经过训练期帧遮蔽、时间自注意力、双向 Mamba 状态更新和质量加权池化，输出当前窗口发生跌倒的概率。

它解决的问题是：摄像头姿态估计输出可能跳变、丢帧或置信度下降，同时“跌倒”通常需要结合一段动作过程判断，不能只依据某一帧的姿态。

这里的“改进”是在已有 **Mamba** 算子之上设计适合骨架时序任务的组合结构和训练方式。项目没有改写 Mamba 的底层选择性扫描算法，也没有实现原始 Fall-Mamba 的 RGB 与音频多模态体系。代码的 **MaskedBiMamba** 类明确将其定义为受 Fall-Mamba 启发的骨架模型。[E01]

1.2 两条比较关系要分清

第一条是结构关系。项目中的 **UniMamba** 可作为理解改动的直接起点：

$$X \rightarrow \text{线性嵌入与位置编码} \rightarrow \text{单向 Mamba} \rightarrow \text{平均池化} \rightarrow \text{分类器}. \quad (1)$$

MaskedBiMamba 在这条路径上加入帧遮蔽、注意力、反向分支和质量池化：

$$X \xrightarrow{\text{训练时遮蔽}} \tilde{X} \xrightarrow{\text{嵌入}} E \xrightarrow{\text{时间注意力}} H \xrightarrow{\text{双向 Mamba 与融合}} H^* \xrightarrow{\text{质量加权}} z \xrightarrow{\text{分类}} \pi_1. \quad (2)$$

第二条是实验关系。我们还将完整模型与 **TCN**、**Transformer Encoder (TE)** 和 **TCNTE** 比较。尤其 TCNTE 是卷积与 Transformer 的组合基线，并不是通过修改同一组 TCNTE 权重得到 MaskedBiMamba。所有模型分别训练，不能把二者差异解释为一个模块的独立贡献。[E01, E04]

1.3 改动、动机和证据之间的对应

改动	实际修改的位置	希望解决的问题	现有证据的含义
使用关节置信度	每个关节由二维坐标扩展为坐标加置信度	区分可靠与不可靠的姿态观测	窗口 F1 与视频 F1 的变化方向不同；仍需结合质量分支解释
帧遮蔽训练	投影前将整帧姿态向量置零	避免依赖少数连续、完整的观测	完整模型缺帧表现稳定，但缺少与无掩码模型的缺帧配对实验
时间自注意力	Mamba 之前加入四头注意力	直接比较窗口中相距较远的姿态	去掉注意力后，平均窗口 F1 降低
双向 Mamba	增加独立反向序列分支	从两个顺序编码动作过程	去掉反向分支后，平均窗口 F1 降低

改动	实际修改的位置	希望解决的问题	现有证据的含义
质量加权池化	平均池化改为质量网络加权	调整各帧对窗口表示的贡献	干净窗口 F1 略有改善，视频 F1 的均值反而降低

关节置信度是主实验各模型共享的输入；加权 focal loss 也是共享训练设置。它们与完整方案有关，但不能都列作相对于其他主实验模型的独有创新。[E02, E04]

2. 从视频到数学输入

2.1 任务、窗口与符号

给定一段视频，经姿态网络提取人体关节点后，对一个时间窗口进行判断：

$$f_\theta : (X, Q) \mapsto \pi_1 \in [0, 1], \quad \hat{y} = \mathbb{I}(\pi_1 \geq 0.5). \quad (3)$$

其中 $y = 1$ 表示跌倒， $y = 0$ 表示非跌倒。 X 表示姿态序列， Q 表示质量序列， θ 是训练得到的全部参数。

符号	含义	主实验取值或形状
T	一个窗口内的时间步数	30
J	保留的身体关节数	12
X	姿态输入矩阵	30×36
Q	帧质量矩阵	30×3
d	外部隐藏特征宽度	64
d_{in}	Mamba 内部扩展宽度	128
n	每个内部通道的状态维度	16
L	每个方向的 Mamba 层数	2
ρ	训练时帧遮蔽概率	0.15

后文省略 batch 维。实际批量输入为 $B \times 30 \times 36$ 和 $B \times 30 \times 3$ 。为便于推导，单帧特征按列向量书写，序列矩阵按这些向量的转置逐行堆叠；矩阵公式中的权重方向据此给出。

2.2 时间采样不是“随便收集 30 帧”

主实验窗口长度 $W = 1.0$ 秒，滑动步长 $S = 0.2$ 秒。对起点为 a 的窗口，代码构造的采样时刻为：

$$\tau_t = a + \frac{t-1}{T}W, \quad t = 1, \dots, T. \quad (4)$$

因此最后一个采样时刻是 $a + 29/30$ 秒，窗口右端点不包含在采样点中。对于原始时间戳 $s_k \leq \tau_t \leq s_{k+1}$ ，每个坐标、关节置信度和检测框特征分别做线性插值：

$$v(\tau_t) = (1 - \lambda)v(s_k) + \lambda v(s_{k+1}), \quad \lambda = \frac{\tau_t - s_k}{s_{k+1} - s_k}. \quad (5)$$

超出缓存时间范围时取边界值。这使不同视频帧率的输入具有一致的时间尺度。**30 个观测值只有在时间间隔符合训练定义时，才代表相同的运动速度。**例如 5 Hz 连续收集 30 帧，首末帧相差 5.8 秒，与主实验的 1 秒窗口不同。[E02]

2.3 保留哪些关节

输入选择 COCO 编号 5 至 16 的 12 个非面部关节：左右肩、肘、腕、髌、膝、踝。设第 t 帧、第 j 个关节的原始信息为：

$$(r_{t,j}^{(x)}, r_{t,j}^{(y)}, c_{t,j}), \quad c_{t,j} \in [0, 1]. \quad (6)$$

置信度反映姿态网络对关键点的输出信心，并不等同于经过校准的“坐标准确概率”。模型可以学习如何使用它，但不能预设所有高置信度关节都正确。

2.4 逐帧归一化：为什么做，又丢失了什么

对每一帧的 x 、 y 两个轴分别进行 min-max 归一化：

$$\bar{r}_{t,j}^{(a)} = \frac{r_{t,j}^{(a)} - \min_k r_{t,k}^{(a)}}{\max(\max_k r_{t,k}^{(a)} - \min_k r_{t,k}^{(a)}, 10^{-4})}, \quad a \in \{x, y\}. \quad (7)$$

为什么它可以减少位置与尺度影响？先忽略分母下限，假设同一帧的某个坐标轴发生正尺度仿射变换 $r'_j = sr_j + b$ ，其中 $s > 0$ 。代入上式：

$$\frac{r'_j - \min_k r'_k}{\max_k r'_k - \min_k r'_k} = \frac{s(r_j - \min_k r_k)}{s(\max_k r_k - \min_k r_k)} = \bar{r}_j. \quad (8)$$

也就是说，平移 b 和正比例缩放 s 被抵消。分母下限用于处理所有关节在某轴上几乎重合的退化情况；此时不再保证上面的严格不变性。

收益是模型较少依赖人物在图像中的绝对位置和大小。代价也很明确：因为两个轴分别缩放，每帧的人体绝对宽高及宽高比信息会丢失；因为每帧独立归一化，身体中心在画面中整体下降的信息也不被直接保留。模型主要依赖归一化后的关节相对布局及其时序变化，不能说它直接从输入读到了真实下落速度或人体高度。

自然姿态误差中的低置信度关节仍会参与归一化极值计算。归档的人工空间缺失测试则在归一化之前把坐标置零，改变了其他关节的尺度，不能隔离缺失本身的作用。2026 年 9 月 21 日修正后的数据流程先归一化、后施加人工缺失，缓存版本升至 schema 2；旧空间缺失实验未重跑，已退出当前结论。[E02]

2.5 构造姿态向量与质量向量

每个关节保留归一化坐标及置信度，按关节展平：

$$x_t = [\bar{r}_{t,1}^{(x)}, \bar{r}_{t,1}^{(y)}, c_{t,1}, \dots, \bar{r}_{t,12}^{(x)}, \bar{r}_{t,12}^{(y)}, c_{t,12}]^\top \in \mathbb{R}^{36}. \quad (9)$$

再从同一帧计算三个整体质量特征：

$$q_t = \begin{bmatrix} \frac{1}{J} \sum_{j=1}^J c_{t,j} \\ \frac{1}{J} \sum_{j=1}^J \mathbb{I}(c_{t,j} \geq 0.2) \\ b_t \end{bmatrix} \in \mathbb{R}^3. \quad (10)$$

这里 b_t 是人体检测框置信度。三个量分别描述关节平均信心、可见关节比例以及人体检测信心。于是 $X = [x_1^\top; \dots; x_T^\top]$, $Q = [q_1^\top; \dots; q_T^\top]$ 。

置信度进入两个位置，作用不同。 x_t 中每个关节的置信度与该关节坐标共同进入时序编码； q_t 则概括整帧质量，供最后的池化网络使用。主实现并未直接用 q_t 修改 Mamba 的状态转移矩阵。[E01, E02]

3. 为什么不能只做单帧或简单时序分类

3.1 单帧姿态存在动作歧义

假设某一帧人物呈水平姿态，这既可能来自跌倒，也可能来自动躺下。仅建模 $P(y | x_t)$ 很难区分这两种过程，而序列模型学习的是 $P(y | x_1, \dots, x_T)$ ：快速姿态变化、变化前的状态以及变化后的状态都可以提供信息。

这只是任务动机，并不保证任何时序模型都能区分所有动作。尤其我们的归一化会删除部分全局运动信息，单个短窗口也可能不包含完整动作过程。

3.2 TCN 与 TCNTE 在做什么

膨胀因果卷积的简化形式为：

$$h_t = \phi \left(\sum_{i=0}^{k-1} W_i x_{t-\delta i} + b \right), \quad (11)$$

其中 k 为核宽度， δ 为膨胀率。TCN 用多个残差卷积块组合局部时间模式，TCNTE 再用 Transformer Encoder 建模帧间关系。主实验 TCN 的通道为 8, 16, 32，核宽度为 5，每个块含两次卷积，膨胀率为 1, 2, 4；理论感受野为：

$$R = 1 + 2(k-1)(1+2+4) = 57. \quad (12)$$

所以不能用“TCN 看不到 30 帧窗口”作为改进理由。真正的区别是**时间信息如何组合**：卷积使用训练后固定的卷积核，而选择性状态空间通过依赖输入的系数控制信息的写入、保留和读出。[E01, E04]

3.3 从 UniMamba 到完整模型的动机

UniMamba 依次更新状态，再对全部时间位置平均池化。它的分类输出已经看到了整个窗口，不能说它完全没有使用后续帧。完整模型希望进一步改善的是：显式的帧间比较、两个扫描顺序下的动作表示、对输入中断的训练适应，以及帧贡献的自适应分配。

下面每一节均按“实际公式 → 原理 → 实现边界”的顺序展开。

4. 改动一：帧遮蔽训练

4.1 实际遮蔽了什么

训练时，对每个窗口的每一帧独立采样保留变量：

$$m_t \sim \text{Bernoulli}(1 - \rho), \quad \tilde{x}_t = m_t x_t, \quad \rho = 0.15. \quad (13)$$

$m_t = 0$ 表示该帧的 36 维姿态全部置零，包含坐标和关节置信度。如果所有帧都被抽中，则恢复第一帧，避免整窗被人工清空。质量向量 q_t 不随之清零。[E01]

因此，这不是每个窗口固定删除 15% 的帧。设实际被遮蔽帧数为 M ，恢复规则执行前 $M \sim \text{Binomial}(T, \rho)$ ；执行后：

$$\mathbb{E}[M] = T\rho - \rho^T \approx 4.5. \quad (14)$$

其中 ρ^T 是全部被遮蔽的概率，因为该情况下会恢复一帧。这是由采样规则推导出的期望值，不是实验测量值。

4.2 为什么可以帮助应对缺帧

没有遮蔽时，优化目标主要是完整输入上的经验风险：

$$\min_{\theta} \frac{1}{N} \sum_i \ell(f_{\theta}(X_i, Q_i), y_i). \quad (15)$$

加入遮蔽后，模型在训练中面对同一动作的多个不完整版本：

$$\min_{\theta} \frac{1}{N} \sum_i \mathbb{E}_{M \sim \mathcal{D}_{\rho}} [\ell(f_{\theta}(M \odot X_i, Q_i), y_i)]. \quad (16)$$

这里 $\mathcal{D}_{\rho}$ 表示包含“至少保留一帧”修正规则的分布。训练时的一次随机遮蔽可视为对该期望的一次 Monte Carlo 采样。模型若只依赖少数关键帧，这些帧被遮蔽时损失就可能变大；优化会鼓励它利用其他时间位置的相关证据。

它是一种输入扰动正则化，**没有额外的重建目标**。模型没有被训练去恢复被遮蔽的坐标，也没有使用 masked autoencoder 式的重建损失。

4.3 遮蔽后还会发生什么

嵌入公式为：

$$e_t = W_e \tilde{x}_t + b_e + p_t, \quad W_e \in \mathbb{R}^{64 \times 36}. \quad (17)$$

p_t 是可学习的位置编码。即使 $m_t = 0$ ，仍有 $e_t = b_e + p_t$ ，因此隐藏 token 不为恒零。时间步没有被删除，模型仍然知道该位置存在，也仍会在注意力和 Mamba 中处理它。

当前实现没有 attention padding mask，没有把该帧权重硬设为零，也没有将保留帧乘以 $1/(1 - \rho)$ 。推理时关闭这一训练增强，令所有 $m_t = 1$ 。

训练中的人工遮蔽与后续鲁棒性测试也不完全相同：人工遮蔽发生在归一化后的 pose 上，质量不变；鲁棒性 `frame_drop` 则先把采样后的 keypoints 和 bbox 一起置零，再生成 pose 与 quality。因此测试中的缺失帧质量也为零。两者都模拟观测中断，但不能称为完全相同的扰动分布。[E01, E02]

5. 改动二：用时间自注意力显式比较帧

5.1 从相似性到加权信息聚合

令 $E \in \mathbb{R}^{T \times 64}$ 为嵌入序列。四个注意力头分别生成查询、键和值。对第 k 个头：

$$Q_k = EW_k^Q + \mathbf{1}(b_k^Q)^{\top}, \quad K_k = EW_k^K + \mathbf{1}(b_k^K)^{\top}, \quad V_k = EW_k^V + \mathbf{1}(b_k^V)^{\top}, \quad (18)$$

其中 $Q_k, K_k, V_k \in \mathbb{R}^{T \times 16}$ ， $W_k^Q, W_k^K, W_k^V \in \mathbb{R}^{64 \times 16}$ 。此处注意力查询矩阵 Q_k 与输入质量矩阵 Q 不是同一个变量。

对时间位置 t 与 u ，先计算点积得分，再在 u 方向归一化：

$$s_{tu}^{(k)} = \frac{(Q_k)_{t,:} (K_k)_{u,:}^\top}{\sqrt{16}}, \quad \beta_{tu}^{(k)} = \frac{\exp s_{tu}^{(k)}}{\sum_{v=1}^T \exp s_{tv}^{(k)}}. \quad (19)$$

该头输出为：

$$O_k = \text{softmax}_{\text{row}} \left(\frac{Q_k K_k^\top}{\sqrt{16}} \right) V_k. \quad (20)$$

于是时间位置 t 可以直接取得其他位置的特征加权和，而无需只依赖扫描状态逐步传递。

5.2 为什么要除以根号维度

在一个用于解释尺度的近似假设下，若查询和键的各分量彼此独立、均值为 0、方差为 1，则 d_h 个乘积的和具有约 d_h 的方差。除以 $\sqrt{d_h}$ 后，方差量级保持为 1，有助于避免 softmax 输入随维度增大而过度饱和。

这个推导是缩放项的动机，不代表训练后网络的查询和键严格满足独立同分布假设。

5.3 多头融合、残差与归一化

将四个头的输出拼接，再投影并加入残差：

$$H = \text{LN} \left(E + [O_1 \| O_2 \| O_3 \| O_4] W^O + \mathbf{1}(b^O)^\top \right). \quad (21)$$

LayerNorm 对每一帧的 64 维向量分别归一化：

$$\text{LN}(v) = \gamma_{\text{LN}} \odot \frac{v - \mu(v)}{\sqrt{\sigma^2(v) + \varepsilon}} + \beta_{\text{LN}}. \quad (22)$$

残差保留原始嵌入信息，使模型不必让所有信息都绕经注意力变换。LayerNorm 则控制每帧特征尺度。

这里仅实现一层多头注意力、残差连接和 LayerNorm，没有再接 **Transformer** 的前馈网络 **FFN**。它也没有因果掩码，所以每个位置能够关注整个已缓冲窗口。`transformer_ffn`、`transformer_layers`、`transformer_dropout` 等基线配置不能原样套到这一模块；此处 `MultiheadAttention` 未显式设置 dropout，按构造默认值为 0。[E01]

5.4 注意力与 Mamba 为什么同时保留

注意力回答的是“当前位置应该直接参考哪些帧”；Mamba 则通过递推决定“沿某个时间方向，哪些内容值得写入和保留”。前者提供直接的两两交互，后者提供有顺序的状态组织方式。

这是组合设计的动机，而不是数学上保证一定更好的结论。需要通过后面的 `no_attention` 消融，判断加入注意力后的平均表现是否符合预期。

6. 先推导 Mamba 的状态空间原理

本节先从经典线性状态空间建立直觉，再落到项目使用的 Mamba v1 算子。Mamba 的输入依赖选择机制来自原始论文；我们使用现有算子，并在外围增加任务相关结构。Mamba 论文；项目对应实现见 [E01, E06]。

6.1 状态为什么有用

考虑连续时间线性系统：

$$\frac{ds(\tau)}{d\tau} = As(\tau) + Bu(\tau), \quad v(\tau) = Cs(\tau) + Du(\tau). \quad (23)$$

其中 u 是输入， s 是保存过去信息的状态， v 是输出。 A 决定已有状态如何演化， B 决定如何写入输入， C 决定如何从状态中读出信息， D 是输入直接到输出的旁路。

在骨架任务中，可以把状态理解为网络对“前面一段姿态变化”的内部摘要。但每个状态维度并没有预先指定为“速度”“倾角”或“跌倒阶段”，这些语义不能仅凭符号推断。

6.2 从微分方程到离散递推

在一个长度为 Δ 的区间内，若输入 u_t 保持不变，连续系统的解为：

$$s_t = e^{\Delta A} s_{t-1} + \left(\int_0^{\Delta} e^{\tau A} d\tau \right) Bu_t. \quad (24)$$

定义：

$$\bar{A} = e^{\Delta A}, \quad \bar{B} = \left(\int_0^{\Delta} e^{\tau A} d\tau \right) B. \quad (25)$$

若 A 可逆，则有 $\bar{B} = A^{-1}(e^{\Delta A} - I)B$ ；不可逆时可保留积分形式。因而得到 $s_t = \bar{A}s_{t-1} + \bar{B}u_t$ 。

把零初态的递推展开：

$$s_t = \sum_{k=1}^t \bar{A}^{t-k} \bar{B} u_k, \quad v_t = \sum_{k=1}^t C \bar{A}^{t-k} \bar{B} u_k + Du_t. \quad (26)$$

这说明状态空间把历史输入通过一个随时间间隔变化的权重核累积到当前输出。如果 A, B, C, Δ 都固定，核 $C \bar{A}^{t-k} \bar{B}$ 只取决于间隔 $t - k$ ，不会依据当前动作内容改变。

6.3 从固定系统到选择性系统

Mamba 让部分系数随输入变化。对于内部通道 a 、状态分量 r ，项目使用的实际递推可写为：

$$\begin{aligned} A_{a,r} &= -\exp(\theta_{a,r}), \\ \Delta_{t,a} &= \text{softplus}(\widehat{\Delta}_{t,a}) > 0, \\ s_{t,a,r} &= \exp(\Delta_{t,a} A_{a,r}) s_{t-1,a,r} + \Delta_{t,a} B_{t,r} u_{t,a}, \\ v_{t,a} &= \sum_{r=1}^n C_{t,r} s_{t,a,r} + D_a u_{t,a}. \end{aligned} \quad (27)$$

其中 $\text{softplus}(x) = \log(1 + e^x)$ 。 A 和 D 是训练得到、推理时固定的参数； Δ_t, B_t, C_t 则由当前层的输入特征生成。对每个内部通道，都保存 $n = 16$ 个状态分量。

公式 (27) 的输入项是 $\Delta B u$ ，不能写成公式 (24) 的完整零阶保持积分系数。它可由 $e^{\Delta A} \approx I + \Delta A$ 得到 $B \approx \Delta B$ 的一阶解释，但实际计算仍对状态转移使用指数。项目导出器与所核对的官方参考扫描均使用这一输入项。E06；Mamba v2.2.2 参考实现

6.4 “选择”怎样体现在公式里

记 $a_{t,a,r} = \exp(\Delta_{t,a} A_{a,r})$ 。由于 $A_{a,r} < 0$ 且 $\Delta_{t,a} > 0$ ，有 $0 < a_{t,a,r} < 1$ 。在固定其他量的直观分析中：较小 Δ 使 a 接近 1，历史状态衰减较慢；较大 Δ 使旧状态衰减更快，同时输入注入系数也变化。

例如仅为解释，取 $A = -1$ ： $\Delta = 0.1$ 时保留系数 $e^{-0.1} \approx 0.905$ ， $\Delta = 1$ 时为 $e^{-1} \approx 0.368$ 。这些是假设参数下的数学例子，不是训练中测得的状态值。

B_t 控制当前输入如何写入状态， C_t 控制当前输出如何读取状态。因为这些量来自特征，模型可以学到与内容相关的更新方式。但 Δ 不是视频采样间隔 1/30 秒；它是内部学习的正值参数，也不能直接解释成实际反应时间。

6.5 展开选择性递推，看到与固定卷积的区别

对单个通道和状态分量，令 $b_{k,a,r} = \Delta_{k,a} B_{k,r}$ ，零初态下：

$$s_{t,a,r} = \sum_{k=1}^t \left(\prod_{j=k+1}^t a_{j,a,r} \right) b_{k,a,r} u_{k,a}. \quad (28)$$

空乘积定义为 1。代入输出后，历史输入 $u_{k,a}$ 经状态通路影响输出的动态核为：

$$K_{t,k,a} = \sum_{r=1}^n C_{t,r} \left(\prod_{j=k+1}^t a_{j,a,r} \right) \Delta_{k,a} B_{k,r}. \quad (29)$$

完整扫描输出仍包含旁路，即 $v_{t,a} = \sum_{k=1}^t K_{t,k,a} u_{k,a} + D_a u_{t,a}$ 。与公式 (26) 相比， $K_{t,k,a}$ 不再只由间隔 $t - k$ 决定，还取决于沿途的输入相关系数。这就是“根据内容选择性保留信息”的具体数学含义。它给模型提供了表达能力，是否学到对跌倒识别有用的保留策略仍由训练和实验决定。

7. Mamba 块在代码中怎样完整计算

前一节只描述扫描核心。实际一个 Mamba 块还包含投影、局部卷积和输出门控，省略这些会使公式与实现不完整。[E06]

7.1 投影为内容支路与门控支路

令该块输入为 $h_t \in \mathbb{R}^{64}$ 。先计算：

$$\begin{bmatrix} \xi_t \\ g_t \end{bmatrix} = W_{\text{in}} h_t, \quad \xi_t, g_t \in \mathbb{R}^{128}. \quad (30)$$

输入投影将 64 维映射到 256 维，再等分为两条 128 维支路。这里 g_t 是 Mamba 内部特征门控，与后面的帧质量门控不是同一机制。

7.2 用短卷积组织邻近时间信息

对 ξ 执行核宽度为 4 的逐通道因果卷积，随后使用 SiLU：

$$u_{t,a} = \text{SiLU} \left(\sum_{i=0}^3 k_{a,i} \xi_{t-i,a} + b_a^{\text{conv}} \right), \quad \text{SiLU}(x) = x\sigma(x). \quad (31)$$

卷积在序列左侧补零，各通道独立执行；系数按时间滞后记号书写。它先提取较短的变化模式，再交由扫描积累更长的上下文。

这里“因果”只描述当前扫描顺序中的卷积和状态更新。在完整模型里，输入已经经过全窗口注意力，而且还有反向分支，所以整个模型不是逐帧因果模型。

7.3 从当前特征生成选择参数

当前内部特征 $u_t \in \mathbb{R}^{128}$ 通过线性投影生成：

$$\begin{bmatrix} r_t \\ B_t \\ C_t \end{bmatrix} = W_x u_t, \quad r_t \in \mathbb{R}^4, \quad B_t, C_t \in \mathbb{R}^{16}, \quad \Delta_t = \text{softplus}(W_\Delta r_t + b_\Delta) \in \mathbb{R}^{128}. \quad (32)$$

低秩步长投影维度为 $\lceil 64/16 \rceil = 4$ 。因此 W_x 输出 $4 + 16 + 16 = 36$ 个值，再用 W_Δ 将 4 维变为各内部通道的 128 维步长。此实现的 B_t, C_t 在通道间共享同一组 16 维系数，而 $A_{a,r}$ 、 $\Delta_{t,a}$ 与 D_a 包含通道维度。

7.4 扫描、门控与输出投影

用公式 (27) 从零初态依次得到 v_t ，再执行：

$$\mathcal{M}(h)_t = W_{\text{out}}(v_t \odot \text{SiLU}(g_t)) \in \mathbb{R}^{64}. \quad (33)$$

最终，项目在每一个 Mamba 块外加残差：

$$h_t^{(\ell)} = h_t^{(\ell-1)} + \mathcal{M}^{(\ell)}(H^{(\ell-1)})_t. \quad (34)$$

代码没有在每个残差 Mamba 块前另加一层 LayerNorm。完整结构中的归一化位于注意力残差之后和方向融合之后。不能把另一种常见 Mamba 堆叠模板直接当作本项目的层结构。

8. 改动三：双向编码与时间对齐

8.1 为什么添加反向分支

跌倒的动作含义往往依赖变化前后两侧的姿态。正向扫描按照“前面发生什么”组织信息，反向扫描按照相反顺序组织相同窗口。两个分支拥有独立参数，使它们能够学习不同的时间组合方式。

由于前面已有全窗口自注意力，正向分支的输入本身也包含后续帧信息。所以双向的增益不能简单解释为“第一次获得未来信息”；更准确的说法是增加一个方向相反、独立参数化的状态编码路径。

8.2 两个方向怎样计算

定义时间反转算子：

$$\mathcal{R}(H)_{t,:} = H_{T+1-t,:}, \quad \mathcal{R}(\mathcal{R}(H)) = H. \quad (35)$$

从相同注意力输出出发：

$$F^{(0)} = H, \quad B^{(0)} = \mathcal{R}(H). \quad (36)$$

两个方向各执行两层残差 Mamba：

$$\begin{aligned} F^{(\ell)} &= F^{(\ell-1)} + \mathcal{M}_f^{(\ell)}(F^{(\ell-1)}), \\ B^{(\ell)} &= B^{(\ell-1)} + \mathcal{M}_b^{(\ell)}(B^{(\ell-1)}), \quad \ell = 1, 2. \end{aligned} \quad (37)$$

8.3 为什么反向输出必须翻回来

假设原序列为 $[x_1, x_2, x_3]$ ，反向分支处理的是 $[x_3, x_2, x_1]$ 。它输出的第一个位置对应原始第三帧。如果直接与正向输出的第一个位置拼接，就会把不同时刻的表示错误地配对。

因此必须先恢复原时间顺序，再拼接和投影：

$$H^* = \text{LN} \left([F^{(2)} \| \mathcal{R}(B^{(2)})] W_f + \mathbf{1} b_f^\top \right), \quad W_f \in \mathbb{R}^{128 \times 64}. \quad (38)$$

这一步把两条 $T \times 64$ 序列变为一条 $T \times 128$ 序列，再融合回 $T \times 64$ 。线性融合可以为不同特征学习不同的方向组合系数；它不是简单平均两个方向，也不是输入相关的动态方向门控。[E01]

8.4 对在线检测意味着什么

模型可以在不断更新的缓冲窗口上重复运行，每次输出当前完整窗口的判断。但它需要该窗口的数据已经到齐，不能在尚未观察到窗口后半部分时产生同等语义的最终结果。

当前实现每个窗口独立运行，并未在滑动窗口之间传递 Mamba 隐状态；它也没有完成跨窗口缓存复用。因此模型内部的递推性质不等于部署时已经实现逐帧状态缓存。

9. 改动四：质量加权池化

9.1 平均池化的问题

设融合后的每帧特征为 $h_t^* \in \mathbb{R}^{64}$ 。普通平均池化为：

$$z_{\text{mean}} = \frac{1}{T} \sum_{t=1}^T h_t^*. \quad (39)$$

它给每一帧相同的系数。若某些帧的姿态观测明显不可靠，固定的 $1/T$ 不一定是合适的分配方式。

为了说明加权的动机，可考虑一个简化模型 $h_t^* = \mu + \epsilon_t$ ，假设噪声独立、零均值，且每一维方差为 σ_t^2 。对满足 $\sum_t \alpha_t = 1$ 的估计 $z = \sum_t \alpha_t h_t^*$ ，其单维噪声方差是 $\sum_t \alpha_t^2 \sigma_t^2$ 。用拉格朗日乘子最小化，可得：

$$\alpha_t^{\text{opt}} = \frac{1/\sigma_t^2}{\sum_u 1/\sigma_u^2}. \quad (40)$$

这说明“不同噪声水平的观测应分配不同权重”在某些假设下有数学依据。本项目没有估计 σ_t^2 ，也不能把上下文混合后的特征当作上述具有独立、零均值噪声的共同均值观测；式 (40) 仅用于解释设计动机，不能据此宣称当前池化是统计最优的。

9.2 实际质量门控网络

项目使用一个小型两层网络，根据三个质量特征产生标量：

$$\begin{aligned}\eta_t &= w_2^\top \text{ReLU}(W_1 q_t + b_1) + b_2, \\ a_t &= \max\{10^{-6}, \sigma(\eta_t)\}, \\ \alpha_t &= \frac{a_t}{\sum_{u=1}^T a_u}, \quad z = \sum_{t=1}^T \alpha_t h_t^*.\end{aligned}\tag{41}$$

$W_1 \in \mathbb{R}^{32 \times 3}$ ，隐藏层激活为 **ReLU**，输出为 Sigmoid。数值下限是 10^{-6} 。由此 $\alpha_t > 0$ 且 $\sum_t \alpha_t = 1$ ，所以 z 是帧特征的凸组合。若 a_t 都相等，退化为平均池化。[E01]

下限保证分母不为零，但也意味着没有帧被严格排除。即使 $q_t = 0$ ，带偏置的网络也可能输出非零权重。输入质量较低并不自动意味着对应帧获得最小权重。

9.3 权重如何被训练出来

令 $S = \sum_u a_u$ 。保持 h_t^* 不变，对池化输出求导：

$$\frac{\partial z}{\partial a_t} = \frac{h_t^* - z}{S}.\tag{42}$$

若 $g_z = \partial \mathcal{L} / \partial z$ ，则：

$$\frac{\partial \mathcal{L}}{\partial a_t} = \frac{g_z^\top (h_t^* - z)}{S}.\tag{43}$$

这表明质量网络是通过分类损失反向传播学习的：一帧特征对降低分类损失是否有帮助，会影响其权重更新。它没有“这一帧质量应该是多少”的独立监督标签。

也因此，质量权重不是人为设置的规则，不保证对三个输入质量分量单调递增，更不是经过标定的可信度概率。观察到高置信度与高权重相关，需要另外记录和分析权重，而不能只凭网络名称断言。

9.4 为什么它有时不能改善干净数据

注意力和 Mamba 已经把多帧信息混合进 h_t^* 。即使第 t 帧原始质量差，其隐藏表示也可能从邻近帧获得有用内容；反之，高质量帧也不一定包含跌倒的判别性瞬间。

另外，质量门控只看到 q_t ，看不到显式的动作重要性特征。低置信度可能恰好出现在快速运动阶段，降低这类帧的权重可能损失有效证据。以上是合理机制解释，现有实验没有单独验证每一条；消融中完整模型的干净窗口 F1 略高，但去掉质量池化后视频 F1 更高、离线误报率更低，说明收益随指标而变化。

10. 分类头与训练目标

10.1 从 64 维窗口表示得到概率

$$\ell = W_c z + b_c \in \mathbb{R}^2, \quad \pi_c = \frac{e^{\ell_c}}{e^{\ell_0} + e^{\ell_1}}, \quad c \in \{0, 1\}. \quad (44)$$

其中 $W_c \in \mathbb{R}^{2 \times 64}$ 。模型 **forward** 返回的是两维原始 logits，训练损失内部计算 log-softmax；评价时再计算 softmax，并以 0.5 为跌倒阈值。

二分类下，也可将跌倒概率写成 $\pi_1 = \sigma(\ell_1 - \ell_0)$ 。因此 0.5 阈值等价于判断跌倒 logit 是否不小于非跌倒 logit。

10.2 为什么使用类别加权

设某个训练划分内类别 c 的样本数为 N_c ，总数为 $N_{\text{train}} = N_0 + N_1$ 。项目自动设置：

$$w_c = \frac{N_{\text{train}}}{2N_c}. \quad (45)$$

于是每类所有样本的权重之和均为 $N_c w_c = N_{\text{train}}/2$ 。在这个意义上，少数类不会仅因样本数量少而在总损失中被大类淹没。

权重只由对应训练集计算。不能用全部测试窗口的类别数代替 N_c ，否则公式虽然相同，实验口径却错了。[E03, E04]

10.3 从交叉熵到 focal loss

对样本 i ，设真实类别概率 $p_i = \pi_{i, y_i}$ 。交叉熵为 $-\log p_i$ 。加权 focal loss 在其前面再乘一个难度相关因子：

$$\mathcal{L} = -\frac{1}{N_b} \sum_{i=1}^{N_b} w_{y_i} (1 - p_i)^\gamma \log p_i, \quad \gamma = 3. \quad (46)$$

高置信度正确样本的 p_i 接近 1，调制因子很小；难样本的 p_i 较小，调制因子较大。以 $\gamma = 3$ 为例： $p_i = 0.9$ 时因子为 0.001， $p_i = 0.5$ 时为 0.125， $p_i = 0.1$ 时为 0.729。这些数值说明的是损失加权方式，并非模型预测示例。

这个思想来自 Focal Loss 原始论文，本项目通过 `log_softmax` 实现二分类版本，并采用训练集频数计算类别权重。[E03]

10.4 如果想进一步理解梯度

对单样本，令 $p = \pi_y$ ，则对任一类别 logit ℓ_j ：

$$\frac{\partial \mathcal{L}_i}{\partial \ell_j} = w_y (\pi_j - \mathbb{I}[j = y]) [(1 - p)^\gamma - \gamma p (1 - p)^{\gamma-1} \log p]. \quad (47)$$

它保留了交叉熵梯度中的 $(\pi_j - \mathbb{I}[j = y])$ 方向，又根据 p 调整幅度。需要注意，极低置信度样本也可能是标签错误或姿态估计失败；强调难样本并不保证只强调有价值的样本。

加权 focal loss 由五个主实验模型共同使用，因此不能把主模型相对基线的全部收益归因于损失函数。

10.5 实际训练设置

主实验采用 Adam, 学习率 10^{-4} , batch size 64, 训练 100 个 epoch, 权重衰减为 0, 梯度范数裁剪阈值为 1.0, 配置启用混合精度和确定性设置。每个运行使用验证集窗口 F1 选择 checkpoint, 训练并不提前停止。[E04, E05]

这意味着“训练 100 轮”和“使用第 100 轮权重测试”是两回事。测试结果来自验证 F1 最优的 checkpoint; 不能按测试集结果重新选择模型轮次或阈值。

11. 把所有步骤接成一次完整前向传播

11.1 张量尺寸对照

阶段	数学对象	输出尺寸 (省略 batch)
12 个关节及置信度	X	30×36
独立质量特征	Q	30×3
训练期姿态遮蔽	$\tilde{X}$	30×36
线性投影与位置编码	E	30×64
四头时间自注意力	H	30×64
正向 Mamba 两层	$F^{(2)}$	30×64
反向 Mamba 两层并翻回	$\mathcal{R}(B^{(2)})$	30×64
拼接	$[F^{(2)} \parallel \mathcal{R}(B^{(2)})]$	30×128
方向投影及归一化	H^*	30×64
质量网络与归一化权重	α	30×1
加权池化	z	64
分类头	ℓ	2

11.2 与实现一致的简化伪代码

输入: pose[B,30,36], quality[B,30,3]

如果当前为训练:

 各帧独立以概率 0.15 将 pose 整帧置零

 若某个窗口全部被置零, 则恢复第一帧

 quality 保持不变

h = Linear36to64(pose) + LearnedPosition

a = MultiHeadAttention(h, h, h) # 四头, 全窗口

h = LayerNorm(h + a)

f = h

重复两次: f = f + ForwardMamba(f)

b = reverse_time(h)

重复两次: b = b + BackwardMamba(b)

b = reverse_time(b)

```

h = LayerNorm(Linear128to64(concat(f, b)))
w = clamp_min(Sigmoid(MLP_ReLU(quality)), 1e-6)
z = sum_time(h * w) / sum_time(w)
logits = Linear64to2(z)
返回 logits

```

正向、反向两个方向以及同方向的不同层都拥有各自参数。该伪代码没有坐标重建、未来帧预测或额外质量监督损失。

12. 计算代价：哪些部分是线性的，哪些不是

固定隐藏宽度、层数和状态维度时，单次 Mamba 扫描对序列长度 T 的计算量是线性的。其状态更新部分约为 $O(Td_{\text{in}}n)$ ，线性投影还带来与通道维度有关的计算，不能只计状态扫描而忽略投影。

我们的完整模型包含两方向、每方向两层 Mamba，又保留全窗口注意力。概略计算量可以写为：

$$O(Td^2 + T^2d + 2L(Tdd_{\text{in}} + Td_{\text{in}}n + Td_{\text{in}}k)), \quad (48)$$

其中省略了固定倍数及较小项， $k = 4$ 。由于存在 T^2d 项，整个 MaskedBiMamba 不能称为关于序列长度严格线性的模型。当 $T = 30$ 时，四头注意力在概念上包含 $4 \times 30 \times 30 = 3600$ 个帧间注意力系数；实际内核是否显式存储它们取决于运行实现。

另一个比较边界是容量：主实验 TE/TCNTE 特征宽度为 32，而 Mamba 宽度为 64，完整模型还增加了反向分支。因此当前主表不是严格等参数量或等 FLOPs 的比较。双向消融也同时改变参数量，无法完全分离“方向结构”和“额外容量”两个因素。

端侧完整帧率还受姿态提取、图像解码、数据传输和缓存调度影响。不能仅凭 Mamba 的复杂度推导，就声称整套系统一定比所有基线更快。

13. 实验怎样判断“改了以后是否有效”

13.1 本文采用哪一组实验

主实验使用 CAUCAFall 的 100 段视频和 GMDCSA-24 的 160 段视频，协议按受试者分组，四折、三个随机种子 42、3407、2026。每个模型有 12 次运行，五个模型共 60 次训练。十个消融变体另外完成 120 次训练；完整模型的消融参照值复用主实验。[E07, E08]

四个测试折合并可重构 7,869 个不同窗口，其中 1,371 个正类、6,498 个负类，覆盖 260 段视频和 14 个带数据集前缀的受试者组。不同模型和随机种子使用相同测试定义。已有预测文件能够核对测试折之间不重叠；完整训练/验证划分及姿态缓存的独立重建仍受本地归档完整性限制。[E11]

另用 190 段 Le2i 视频作外部测试，评估主实验得到的 checkpoint；Le2i 不用于这些 checkpoint 的拟合。该集合含 12,650 个评价窗口。本文不把更早的 Le2i-CAUCAFall 主表或单独的 TCNTE 复现实验混入当前主实验。[E10, E11]

13.2 窗口标签怎样生成

对一个长度 W 的窗口 $[a, a + W)$ ，计算其与跌倒标注区间的重叠比例：

$$r(a) = \frac{\sum_j |[a, a + W) \cap I_j^{\text{fall}}|}{W}. \quad (49)$$

代码对标注区间逐项累加重叠；在区间不互相重叠时，该值就是窗口内跌倒所占时长比例。 $r(a) \geq 0.5$ 时标为正类， $r(a) = 0$ 时为负类； $0 < r(a) < 0.5$ 的过渡窗口剔除。与 `ignore` 区间相交的窗口也剔除。

主协议还启用 `exclude_after_fall`：对有跌倒标注的视频，若窗口起点不早于最后一个跌倒区间的结束时刻，则排除该窗口。因此这是针对动态跌倒过程的任务定义，不能把所有“已经躺在地上”的时间都理解为正类。[E12]

13.3 窗口、视频与事件指标分别回答什么

窗口指标对每个窗口进行二分类：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2TP}{2TP + FP + FN}. \quad (50)$$

精确率回答“预测为跌倒的窗口里，有多少是真的”，召回率回答“真实跌倒窗口里，找到了多少”。F1 综合两者，但不体现所有误判代价。

视频级评价采用：

$$\pi_v = \max_{i \in \mathcal{W}_v} \pi_i, \quad y_v = \max_{i \in \mathcal{W}_v} y_i. \quad (51)$$

只要某视频有一个预测阳性窗口，整个视频即判为阳性。这可以提高视频召回，也会放大偶发误报。一个视频判对，不代表跌倒发生期间的所有窗口都判对，更不代表及时触发了现场报警。

事件级评价将相交或接触的正类窗口合并为区间，对预测和参考分别操作；参考事件来自窗口标签，而不是直接拿原始标注的动作起止点。每个参考事件按顺序匹配第一个尚未使用、且有正时长交集的预测事件。[E05]

离线每小时误报率定义为：

$$\text{FA/h} = \frac{N_{\text{unmatched predictions}}}{\frac{1}{3600} \sum_v \left(\max_{i \in \mathcal{W}_v} \text{end}_i - \min_{i \in \mathcal{W}_v} \text{start}_i \right)}. \quad (52)$$

分母包含正类与负类视频的评价覆盖时间，不是纯非跌倒监测时间，也不是数小时现场连续运行。四折测试覆盖总计 1,827.4 秒。因此后面的约 200 次/小时是这一**离线定义**下的数值，不能直接解释成网页最终报警频率。[E11]

归档中的时间差为匹配预测区间起点减参考区间起点，可为负；它不包含窗口积累、姿态提取、推理与网络耗时，不能用作端到端延迟。

13.4 均值、标准差与百分点

对一个模型的 12 次运行结果 $s_1, \dots, s_{12}$ ，使用：

$$\bar{s} = \frac{1}{12} \sum_{i=1}^{12} s_i, \quad \text{SD}(s) = \sqrt{\frac{1}{11} \sum_{i=1}^{12} (s_i - \bar{s})^2}. \quad (53)$$

表中“均值 $\pm$ SD”描述运行间波动，不是置信区间，也不是 12 个互相独立的人体样本；同折不同种子复用了相同测试集。本项目未预先指定配对显著性检验，以下使用“均值提高”“观察到”等描述，不将小差异称为统计显著。

后续表格为便于阅读，把比例指标乘以 100。例如 F1 的 63.95 对应 0.6395；两模型 F1 从 62.54 到 63.95，差约 **1.41 个百分点**，不是提高 1.41 倍。

14. 主实验：得到的是性能取舍，而非全面领先

14.1 未加额外测试扰动的主结果

各行均为 12 次运行。精确率、召回率、视频 F1 列展示均值，窗口 F1 展示均值及样本标准差；完整精度见对应汇总文件。[E07]

模型	窗口精确率	窗口召回率	窗口 F1 (均值 $\pm$ SD)	视频 F1
TCN	56.17	66.52	60.28 $\pm$ 7.37	74.86
TE	59.85	74.53	65.81 $\pm$ 7.66	76.86
TCNTE	57.43	70.63	62.54 $\pm$ 6.75	75.91
UniMamba	57.59	71.55	63.38 $\pm$ 6.84	75.92
MaskedBiMamba	60.48	68.22	63.95 $\pm$ 7.28	76.32

从最直接的窗口分类看，完整模型 F1 为 0.63946，高于 TCNTE 的 0.62541，低于 TE 的 0.65810。完整模型的窗口精确率最高，但召回率并不最高。

14.2 与 TCNTE 相比具体变化了什么

从未四舍五入的均值计算，完整模型相对 TCNTE：

- 窗口 F1 提高 **1.4050 个百分点**。
- 窗口精确率提高 **3.0493 个百分点**，窗口召回率降低 **2.4085 个百分点**。
- 视频 F1 提高 **0.4061 个百分点**。
- 事件召回率降低 **3.2365 个百分点**。
- 离线 FA/h 从 **228.73** 降至 **198.45**，减少约 **30.28 次/小时**，相对下降 **13.24%**。

这些数值共同说明：在阈值固定为 0.5 的当前实验里，完整模型产生的阳性预测更准确，误报事件均值更低，但也漏掉了更多正类窗口和参考事件。不能把更高精确率单独写成“跌倒识别能力全面提高”。

14.3 与最强干净数据基线相比

TE 的窗口 F1、视频 F1、窗口 AUROC 和事件召回均值均为主表最高。完整模型的窗口 F1 比 TE 低 **1.8642 个百分点**，视频 F1 低 **0.5433 个百分点**；精确率高 **0.6289 个百分点**。[E07]

所以，若目标是当前干净测试集上最高的 F1，主表支持选择 TE；若任务尤其关注观测中断，则还要看后面的缺帧结果。这里仅有完整模型与 TCNTE 的扰动比较，尚不能据此排定 TE、TCN、UniMamba 在缺帧条件下的名次。

15. 消融实验：每一个模块是否都值得保留

15.1 去掉一个模块后会怎样

下表是在没有额外测试扰动的条件下比较；各变体分别重新训练。最后一列为“完整模型 F1 减去该变体 F1”，正值代表完整模型更高。[E08]

变体	窗口 F1 (均值 $\pm$ SD)	视频 F1	FA/h	完整 - 变体的 F1 差
完整模型	63.95 $\pm$ 7.28	76.32	198.45	0.00
去掉双向	62.36 $\pm$ 5.78	75.18	216.33	+1.58
去掉时间注意力	62.30 $\pm$ 6.38	74.59	234.99	+1.64
去掉质量池化	63.54 $\pm$ 7.80	77.29	189.19	+0.40
去掉帧遮蔽训练	65.16 $\pm$ 5.91	77.06	187.85	-1.21
去掉 pose 中的置信度	64.29 $\pm$ 5.13	75.36	221.97	-0.34
同时去掉置信度及质量池化	63.90 $\pm$ 5.94	75.75	210.32	+0.05

双向分支和时间注意力都有较一致的描述性支持：完整模型的窗口 F1、视频 F1 更高，离线 FA/h 更低。但去双向还会减少参数量，效果不能完全归因于时间方向本身。

质量池化的窗口 F1 均值增加 **0.4025 个百分点**，但视频 F1 降低 **0.9691 个百分点**、FA/h 增加约 **9.26**。它并非所有指标上的增益模块。

帧遮蔽训练在干净数据上具有代价：完整模型窗口 F1 比无掩码变体低 **1.2127 个百分点**。这与“训练时减少可见信息可能损失干净数据性能”的机制相容，但还不能单凭这个表证明它换来了多少抗缺帧收益。

删除 pose 中的置信度后，输入由 36 维变为 24 维，质量分支仍保留置信度摘要。因此这个变体不是完全不使用置信度。其窗口 F1 更高，但视频 F1 更低、误报更多，说明各指标之间同样存在取舍。

15.2 为什么 15% 不是已经证明的最佳比例

训练遮蔽概率 ρ	窗口 F1 (均值 $\pm$ SD)	视频 F1	FA/h
0.00	65.16 $\pm$ 5.91	77.06	187.85
0.05	64.23 $\pm$ 5.95	76.85	189.41
0.10	62.70 $\pm$ 5.85	76.09	205.97
0.15	63.95 $\pm$ 7.28	76.32	198.45
0.20	63.46 $\pm$ 6.46	76.49	188.02
0.30	61.49 $\pm$ 6.27	76.51	194.44

这些均值不呈严格单调变化。较高遮蔽率如 0.30 的干净窗口 F1 更低，但不能从有限运行推导出连续、普适的最优曲线。主配置的 0.15 是当前采用的参数，并不是已经被这组数据证明的全局最优值。

如果以后需要按“干净表现与缺帧表现的折中”选择比例，应事先定义验证目标，再在验证集上选择；不能按最终测试表挑完比例，再把同一测试表当作未经选择的性能估计。

15.3 消融目前能够回答与尚不能回答的问题

当前消融能回答：“在其他配置保持相应设定时，重新训练并去掉某一模块，干净测试的平均结果如何变化。”

当前还不能回答：“完整模型在 30% 缺帧时的优势中，究竟有多少来自遮蔽训练，有多少来自注意力、双向或质量池化。”已有鲁棒性归档仅包含完整模型与 TCNTE，没有无掩码等变体的同条件缺帧结果。配置文件中继承了 `robustness` 字段，并不代表这些变体已经实际执行并保存该评估。[E08, E09]

16. 鲁棒性与跨数据集：最明确的收益在哪里

16.1 当前评价与历史条件的边界

鲁棒性测试对选定 checkpoint 的输入施加扰动，不重新训练。当前结论保留整帧丢失与置信度噪声；随机关节和下半身缺失仅保留为有混淆的历史记录。[E02, E09]

扰动	数学或操作定义	影响
整帧丢失	每个时间步以概率 p 将 keypoints 和 bbox 全置零	时间观测中断，保持 30 个位置
随机关节丢失	每帧每关节以概率 p 将 (x, y, c) 置零	历史条件：归一化受影响，已排除
置信度噪声	$c'_{t,j} = \text{clip}(c_{t,j} + \epsilon, 0, 1)$, $\epsilon \sim \mathcal{N}(0, \sigma^2)$	同时影响 pose 置信度与质量摘要
下半身缺失	六个髋、膝、踝关节全置零	历史条件：归一化受影响，已排除

前三类中的 p 与 σ 不能混用： $p = 0.3$ 表示丢失概率， $\sigma = 0.3$ 表示加性高斯噪声标准差。测试中的“丢帧”是输入置零模拟，并没有删除时间位置、改变序列长度或重新插值填补缺失帧。

16.2 主数据上的有效扰动结果

以下全部为窗口 F1，单位与前表相同，每项均为 12 次 checkpoint 评估的均值及样本标准差。[E09]

条件	MaskedBiMamba	TCNTE
干净输入，独立重评估	63.95 ± 7.28	62.55 ± 6.77
整帧丢失 10%	64.90 ± 6.90	56.92 ± 4.49
整帧丢失 20%	64.44 ± 6.14	49.53 ± 6.07
整帧丢失 30%	62.76 ± 5.07	43.61 ± 6.69
置信度噪声 $\sigma = 0.1$	63.88 ± 7.05	62.84 ± 6.79
置信度噪声 $\sigma = 0.2$	63.79 ± 7.07	62.58 ± 6.87
置信度噪声 $\sigma = 0.3$	62.77 ± 6.81	61.66 ± 6.53

注意：TCNTE 独立鲁棒性重评估的 clean F1 是 0.625543，主实验是 0.625410。原归档记录有一个正类窗口的阈值判断变化，两组数据分别保持原值；不能人为改成一致，也不能在缺乏证据时断定具体数值原因。[E11]

16.3 用降幅衡量缺帧稳定性

定义某模型从干净输入到指定扰动的 F1 降幅：

$$D(p) = F_1(\text{clean}) - F_1(\text{frame drop} = p). \quad (54)$$

30% 整帧丢失时，完整模型从 0.639460 降至 0.627567，降幅 **1.1893 个百分点**；TCNTE 从 0.625543 降至 0.436051，降幅 **18.9492 个百分点**。两者在这一条件下相差 **19.1515 个百分点**。

这比只看干净主表的约 1.41 个百分点差异更能体现当前完整方案的特点：**在本实验的随机整帧置零条件下，完整模型的窗口 F1 更稳定**。10% 或 20% 丢帧时其均值略高于 clean，只是这次评估的观察值，不能据此说丢帧本身会改善识别。

16.4 为什么不能推广成“对所有遮挡都鲁棒”

当前缺帧测试只证明随机整帧置零条件下的表现。它没有改变原始图像中的遮挡、光照和机位，也不能证明对持续空间遮挡的鲁棒性。归档空间缺失实验同时影响了坐标尺度，必须使用修正后的预处理重新评价，才能回答该问题。

16.5 Le2i 外部数据上是否有缺帧优势

下表为主协议 checkpoint 在同一 Le2i 外部集合上的窗口 F1，未在 Le2i 上再训练。[E10]

条件	MaskedBiMamba	TCNTE
干净输入	46.87 ± 5.40	49.50 ± 5.68
整帧丢失 10%	47.24 ± 5.02	39.11 ± 4.12
整帧丢失 20%	46.68 ± 4.64	32.23 ± 3.51
整帧丢失 30%	45.07 ± 4.32	27.82 ± 2.72
置信度噪声 $\sigma = 0.3$	43.03 ± 6.21	43.69 ± 6.93

外部干净输入下，完整模型比 TCNTE 的窗口 F1 低 **2.6339 个百分点**。但在 30% 缺帧时，它比 TCNTE 高 **17.2542 个百分点**，相对自身干净结果仅降低 **1.7947 个百分点**；TCNTE 降低 **21.6828 个百分点**。这再次支持“特定缺帧条件下表现稳定”，同时表明干净跨数据集泛化还不理想。

16.6 为什么外部视频 F1 接近 0.83 仍要看误报

外部评价标签中有 130 个正视频、60 个负视频。如果不进行有效区分，把所有视频都预测为跌倒，则 $TP = 130$ 、 $FP = 60$ 、 $FN = 0$ ，得到：

$$F_{1,\text{all positive}} = \frac{2 \times 130}{2 \times 130 + 60} = 0.8125. \quad (55)$$

完整模型干净视频 F1 为 0.8299，TCNTE 为 0.8307，只比这个简单基线略高。两者的视频特异度 $TN/(TN + FP)$ 分别只有 0.1958 和 0.1736。因此，约 0.83 的视频 F1 不能单独证明良好的跨场景实用性；窗口 F1 和对非跌倒视频的排除能力同样需要报告。[E10, E11]

17. 从训练模型到树莓派：已经实现了什么

17.1 为什么需要可移植扫描实现

训练时的 `mamba-ssm` 使用 CUDA 相关算子。为了在树莓派 CPU 上运行，导出器用普通 PyTorch 操作实现同样形式的固定长度扫描，再导出 ONNX。对 $T = 30$ 的每个位置展开状态更新，使 ONNX Runtime 执行投影、卷积、指数、乘加与门控，无需 CUDA 扩展。[E06]

这里保持的是模型结构和已加载参数的计算形式，并不是把时序分类器部署到 Hailo 上。当前 Hailo 执行姿态网络，MaskedBiMamba 仍由树莓派 CPU 执行。[E13, E14]

17.2 当前部署已修复早期输入语义差异

早期单输入导出模式只接收 `pose`，并把第三个质量分量替换为关节平均置信度，与训练时的检测框置信度不同。该兼容模式仍存在于导出器中，但不能把它当作当前离线部署路径。

截至 10 月 7 日核对的离线实现，部署继续采用具有独立 `pose` 和 `quality` 输入的 `masked_bimamba_quality.onnx`；运行时实际传入检测框置信度，并按时间戳构造一秒窗口、插值至 30 步，约每 0.2 秒更新。部署模型的选择记录来自主实验 `checkpoint`。[E13]

因此，9 月 19 日旧审查中“30 个接收帧等于较长时间”和“第三质量特征被替换”的问题，应作为历史差异与兼容路径注意事项，不应不加区分地描述为当前离线系统仍然存在的问题。

17.3 导出一致性检查证明到哪一步

导出器会比较便携 PyTorch 实现与 ONNX Runtime 在一个固定随机输入上的 logits，要求最大绝对差不超过 2×10^{-4} 。部署记录给出的双输入导出差值约为 3.6×10^{-7} 。[E06, E13]

这证明该次导出样本的数值一致性，不是完整真实测试集上“原 CUDA 实现、便携实现、ONNX 实现”三者的全面等价检验。若后续更改结构或输入特征，应在同一批真实缓存窗口上重做三方对照。

17.4 设备测试怎样解释

9 月 20 日记录显示：同规模 YOLOv8s 的 CPU ONNX 完整流程约为 **1.73 fps**，Hailo 路径约为 **20.56 fps**；时序分类器每窗口约 **7.7 ms**。Hailo 路径相对 CPU 约 11.9 倍的吞吐率提升主要来自姿态网络加速及整条流程变化，不能写成“双向 Mamba 比 Transformer 快 11.9 倍”。[E14]

固定的 40 段合成视频测试得到 $TP = 20, FN = 0, FP = 8, TN = 11$ ，另有 1 段没有有效输出。有输出覆盖率为 $39/40 = 97.5\%$ ，有输出样本准确率为 $31/39 = 79.49\%$ ，视频 F1 为 0.8333。这是设备运行与合成视频上的另一组测试，不能替换主实验或作为真实场景准确率。[E14]

此外，20 段跌倒视频全部出现过阳性预测，并不等于 20 段都在标注跌倒区间内及时检测到；补充记录中，只有 14 段出现了阳性窗口，且该窗口的终点落在标注跌倒区间内。这进一步说明视频级结果与动作时刻识别要分开解释。

当前运行时还会在有效姿态不足时不给出分类结果。对这类情况应显示“无有效输出”，而不能自动记为正确非跌倒。

17.5 固定确认规则回放

12 组主实验测试序列的回放得到确认事件召回率 0.7752 ± 0.0958 、每评价小时 66.7 ± 45.2 个未匹配确认告警，平均确认偏移为 1.88 ± 0.28 秒。规则没有通过此次测试集回放调参。参考事件由正类窗口合并，偏移从参考区间起点到确认窗口终点计算；它不是原始动作起点到云端告警的时延。证据见结题报告/[review_2026-09-21/alert_replay.json](#)。这些分段视频结果不能代表连续监护通知率。

17.6 当前工作台和服务验收

10 月 7 日已更新并核对树莓派三页本地工作台、云端工作台及令牌保护的私有状态桥接。当前页面在无有效人体、预测过期或端侧断连时不显示旧概率为当前判断；云端历史保留原始采集时间，可筛选、分页与导出。升级快照为 3304 条分类窗口、306 条云端事件、待传 0；这些是操作记录数量，不是新增模型测试样本。模型结构、权重与 9 月吞吐率/准确率实验继续保持原协议。源码和服务证据见 结题报告/[review_2026-10-07/](#)，公开摘要见 [pre-rep/results/deployment/](#)。[E15]

18. 怎样准确概括改进及下一步验证

17.6 当前工作台和服务验收

10月7日已更新并核对树莓派三页本地工作台、云端工作台及令牌保护的私有状态桥接。当前页面在无有效人体、预测过期或端侧断连时不显示旧概率为当前判断；云端历史保留原始采集时间，可筛选、分页与导出。升级快照为3304条分类窗口、306条云端事件、待传0；这些是操作记录数量，不是新增模型测试样本。模型结构、权重与9月吞吐率/准确率实验继续保持原协议。源码和服务证据见 结题报告/review_2026-10-07/，公开摘要见 pre-rep/results/deployment/。[E15]

18.1 可以用于技术报告的完整表述

我们的改进以骨架序列为输入，在单向 Mamba 分类器上加入训练期随机帧遮蔽、时间自注意力、独立参数的双向 Mamba 分支和质量加权池化。输入同时保留关节置信度，质量分支根据平均置信度、可见关节比例及人体框置信度学习帧权重。Mamba 通过输入相关的步长、写入和读出系数动态组织时序信息；注意力和双向结构补充了窗口内部的帧间关系与两种扫描顺序。

在当前四折、三随机种子的主实验中，完整模型相对 TCNTE 的窗口 F1 提高约 1.41 个百分点，精确率提高约 3.05 个百分点，离线未匹配预测事件率均值降低约 13.24%，同时窗口及事件召回有所下降。最清晰的优势出现在随机整帧缺失：30% 缺帧时，主数据上的窗口 F1 为 0.6276，而 TCNTE 为 0.4361；外部 Le2i 上也观察到相同方向的稳定性优势。

消融支持双向分支和时间注意力在当前配置下的描述性收益，但帧遮蔽、质量池化和置信度输入的效果随指标而变化。完整模型没有在所有干净数据指标上超过 TE，当前证据也不能把缺帧收益单独归因于某个模块。跨场景误报仍是部署问题。旧空间缺失结果受归一化混淆影响，不能用来判断模型对关节缺失的性能；该问题需要重评估。[E07-E11]

17.6 当前工作台和服务验收

10月7日已更新并核对树莓派三页本地工作台、云端工作台及令牌保护的私有状态桥接。当前页面在无有效人体、预测过期或端侧断连时不显示旧概率为当前判断；云端历史保留原始采集时间，可筛选、分页与导出。升级快照为3304条分类窗口、306条云端事件、待传0；这些是操作记录数量，不是新增模型测试样本。模型结构、权重与9月吞吐率/准确率实验继续保持原协议。源码和服务证据见 结题报告/review_2026-10-07/，公开摘要见 pre-rep/results/deployment/。[E15]

18.2 对“为什么这样改”的简明回答

问题	设计回答	当前结果回答
某些帧暂时不可用	遮蔽增强、时间信息融合和状态记忆	整体方案随机缺帧更稳定；单模块贡献尚待隔离
相隔较远的姿态需要比较	在扫描前使用时间注意力	去掉后窗口与视频 F1 均值降低
动作前后顺序都可能有帮助	两个独立方向扫描后对齐融合	去掉反向路径后均值降低，同时容量也减少
观测质量不一致	用三维质量向量学习池化权重	窗口 F1 略增，视频 F1 与误报指标未获益
跌倒与非跌倒数量不平衡	全模型统一使用类别加权 focal loss	提供平衡训练目标，但未单独做损失函数收益消融

17.6 当前工作台和服务验收

10月7日已更新并核对树莓派三页本地工作台、云端工作台及令牌保护的私有状态桥接。当前页面在无有效人体、预测过期或端侧断连时不显示旧概率为当前判断；云端历史保留原始采集时间，可筛选、分页与导出。升级快照为 3304 条分类窗口、306 条云端事件、待传 0；这些是操作记录数量，不是新增模型测试样本。模型结构、权重与 9 月吞吐率/准确率实验继续保持原协议。源码和服务证据见 结题报告/review_2026-10-07/，公开摘要见 pre-rep/results/deployment/。[E15]

18.3 最值得补做的验证

首先，在相同测试窗口、相同扰动掩码下，评估完整模型、无帧遮蔽、无质量池化、无双向及无注意力变体。对变体 v 计算：

$$G_v(p) = D_v(p) - D_{\text{full}}(p), \quad (56)$$

其中 D 来自公式 (54)。 $G_v(p) > 0$ 表示完整模型在该扰动下的 F1 降幅更小；同时仍应报告绝对 F1，避免“起点很低所以降得少”的误读。这项实验最直接检验各个模块对缺帧稳定性的作用。

其次，应先用已修正的人工缺失流程重评估空间缺失，再考虑归一化和增强方式，例如只用可靠关节估计归一化尺度，并显式保留髋中心轨迹、人体宽高比等信息。这些是**建议实验**，尚未实现和验证；改变特征时应同时调整训练和部署输入，不能只修改推理端。

最后，比较等参数量的单向/双向模型，在验证集上确定阈值，并在连续真实视频上测量漏报、最终报警频率与从动作开始计时的端到端延迟。这样才能把“离线窗口分类的改善”进一步连接到实际使用效果。

附录 A. 常见误解速查

容易产生的误解	与实际实现一致的解释
每个窗口固定丢掉 15% 帧	每帧独立采样，整窗全被遮蔽时恢复第一帧
mask 后 token 恒为零	pose 为零，但投影偏置、位置编码和后续时序混合仍存在
模型把缺帧重建出来了	只用分类损失训练，没有坐标重建目标
质量越高一定权重越大	MLP 无单调约束，权重由分类目标学习
加了 Mamba 就整体线性复杂度	前置自注意力仍包含关于 T 的二次项
双向首次让模型看到后续帧	前置注意力已经全窗口交互；双向增加另一种扫描路径
单向模型只用最后一帧	UniMamba 平均池化全部时间位置的特征
F1 高一点就是显著改善	当前提供描述性均值和标准差，未给出预先设计的显著性检验
抗缺帧就是抗任意遮挡	当前只验证特定姿态帧扰动；旧空间缺失结果已排除，真实遮挡未评价
视频判断正确就是及时报警	最大窗口概率规则不约束阳性发生的具体时刻
当前部署仍只有 pose 输入	新离线部署采用独立 quality 输入和一秒重采样

附录 B. 公式与代码定位

以下路径以项目目录 小组项目/跌倒检测/ 为根，行号对应本文编写时的代码。公式是对代码的解释；若后续实现变化，应重新核对。

本文内容	源文件与主要位置
插值、BODY12、归一化、质量	code/src/fallbench/data.py, 16–44、172–190 行
帧遮蔽	code/src/fallbench/models.py, 178–185 行
嵌入、注意力、双向与池化	code/src/fallbench/models.py, 154–175、187–213 行
UniMamba 开关设置	code/src/fallbench/models.py, 225–231 行
Mamba 块及扫描展开	code/scripts/export_mamba_onnx.py, 28–76 行
质量兼容模式与双输入导出	code/scripts/export_mamba_onnx.py, 117–171 行
加权 focal loss 与类别权重	code/src/fallbench/losses.py, 8–38 行
训练和窗口预测	code/src/fallbench/engine.py, 19–73 行
视频和事件评价	code/src/fallbench/engine.py, 89–146 行
标签与跌倒后剔除规则	code/scripts/build_windows.py, 45–65 行
当前一秒窗口与双输入部署	webui/edge/offline/edge_runtime.py, 101–138 行

附录 C. 证据索引与复核范围

文中 E 编号指向以下本地材料。代码和实验档案是本项目行为与结果的主要依据；外部论文只用于方法背景，不用于替代本项目的测量。机器核对记录保存在本目录的 `evidence/` 中，并未标记为人工审核或投稿批准。

- **E01 模型结构**: code/src/fallbench/models.py。
- **E02 数据输入及测试扰动**: code/src/fallbench/data.py。
- **E03 损失函数**: code/src/fallbench/losses.py。
- **E04 已执行主配置**: 实验结果/gmdcsa24_gpu_2026-09-18/outputs/gmdcsa24_main_v1/masked_bimamba/fold_0/seed_42/resolved_config.yaml，另对照同组其余运行及 code/configs/main_protocol.yaml。
- **E05 训练及评价实现**: code/src/fallbench/engine.py、code/scripts/train.py。
- **E06 可移植 Mamba 与导出器**: code/scripts/export_mamba_onnx.py。
- **E07 主结果**: 实验结果/gmdcsa24_gpu_2026-09-18/outputs/gmdcsa24_main_v1/summary/ 下的 summary.csv 与 all_runs.csv。
- **E08 消融结果**: 同一 outputs/ 下 gmdcsa24_ablations_v1/summary/ 的 summary.csv 与 all_runs.csv。结果包含三个种子；早期消融计划文件的单种子配置不代表最终运行总数。
- **E09 主数据扰动结果**: 同一 outputs/ 下 gmdcsa24_robustness_v1/ 的 summary.csv 与 all_runs.csv。
- **E10 外部 Le2i 结果**: 同一 outputs/ 下 gmdcsa24_external_le2i_v1/ 的 summary.csv 与 all_runs.csv。
- **E11 既有独立数据复核**: 结题报告/review_2026-09-19/data_audit.md、data_audit_results.json 及 结题报告/RESULTS_PROVENANCE.md；其中设备现状以 E13、E14 的后续记录为准。
- **E12 窗口构建规则**: code/scripts/build_windows.py。
- **E13 当前离线部署**: webui/edge/offline/README.md、edge_runtime.py、deployment_selection.json。
- **E14 设备与补充测试**: 结题报告/树莓派测试说明.md、结题报告/补充实验记录.md，原始设备记录见 结题报告/review_2026-09-20/pi_results/。

本次新核对从四套 `all_runs.csv` 重新计算了 1,593 个汇总均值、标准差及运行计数标量，并从 708 条运行/条件记录的混淆矩阵重算 7,080 个窗口和视频分类指标，均与归档一致。本次未重新训练或推理；鲁棒性与外部档案未保留逐窗口概率，所以不能由这些档案独立重建其 AUROC 和事件序列。主实验逐窗口及历史选择规则的更全面核对，引用 E11 已保存的复核记录。

外部原始方法来源：

1. Albert Gu, Tri Dao, *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*, 论文。用于选择性状态空间的原理背景。
2. State Spaces, Mamba v2.2.2, 选择性扫描参考代码。用于确认 ΔBu 输入项、状态更新与 SiLU 门控形式。
3. Tsung-Yi Lin 等, *Focal Loss for Dense Object Detection*, 论文。用于 focal 调制因子的来源；项目具体权重及 γ 以本地代码和配置为准。

附录 D. 用一个可手算的例子串起状态、双向与池化

本例全部参数均为人为设定的教学数值，不是训练模型的参数或真实视频的预测；它省略投影、注意力、卷积、多维状态、残差和归一化，只展示几种机制的计算关系。

第一步，设定三帧标量输入。令 $u = [1, 0, 2]$ ，中间帧以零表示缺失；采用零初态和简化递推 $s_t = 0.8s_{t-1} + 0.5u_t$ 。将输出简化为 $v_t = s_t$ 。

第二步，正向扫描。

$$s_1 = 0.5, \quad s_2 = 0.8 \times 0.5 = 0.4, \quad s_3 = 0.8 \times 0.4 + 0.5 \times 2 = 1.32. \quad (57)$$

中间帧的输入为零，状态仍为 0.4，说明此前信息可通过递推保留。它没有恢复中间帧真实坐标，只保留了已有内部信息。

第三步，反向扫描并对齐。对 $[2, 0, 1]$ 用同一组教学系数计算，得到 $[1, 0.8, 1.14]$ ；翻回原顺序后为 $[1.14, 0.8, 1]$ 。实际网络的两个方向参数独立，本例取相同系数只是为了便于手算。

第四步，简化方向融合。为便于计算，取两个方向的平均作为融合值：

$$h^* = \frac{1}{2}([0.5, 0.4, 1.32] + [1.14, 0.8, 1]) = [0.82, 0.60, 1.16]. \quad (58)$$

实际网络使用可学习线性投影与 LayerNorm，并不固定为平均。这里的例子说明两个方向对齐后，才能逐位置组合。

第五步，质量加权池化。假设质量网络输出 $a = [0.9, 0.2, 0.8]$ ，则总权重为 1.9，得到：

$$\alpha = \left[\frac{0.9}{1.9}, \frac{0.2}{1.9}, \frac{0.8}{1.9} \right], \quad z = \frac{0.9 \times 0.82 + 0.2 \times 0.60 + 0.8 \times 1.16}{1.9} = 0.94. \quad (59)$$

均值池化则为 $(0.82 + 0.60 + 1.16)/3 = 0.86$ 。本例给中间帧较小权重，是人为设定的场景；实际质量网络并不保证自动产生这一顺序。

第六步，分类与损失。再人为设定分类器 logits 为 $[0, 2z - 1]$ ，得到：

$$\pi_1 = \frac{e^{0.88}}{1 + e^{0.88}} \approx 0.7068. \quad (60)$$

若假设真实标签为跌倒、类别权重为 1、 $\gamma = 3$ ，该样本 focal loss 为：

$$\mathcal{L} = -(1 - 0.7068)^3 \log(0.7068) \approx 0.00875. \quad (61)$$

这个例子将“缺失输入仍可保留状态 → 两个方向对齐 → 帧权重归一化 → 概率 → 损失”串成一次手算。概率升高并不天然代表改善：若真实标签是非跌倒，升高反而是错误方向。实际效果仍必须由第 14–16 章的实验评价决定。

历史补充：已排除的空间缺失条件

以下原始归档仅供追溯，不用于当前模型结论。置零发生在归一化之前，导致剩余关节坐标同时重缩放。前四行为主协议结果，后两行为外部 Le2i；单位为窗口 F1 百分比，数值未经改写。

历史条件（已排除）	MaskedBiMamba	TCNTE
随机关节丢失 10%	43.21 ± 5.56	45.39 ± 9.72
随机关节丢失 20%	37.74 ± 4.86	39.47 ± 7.35
随机关节丢失 30%	34.99 ± 3.90	35.63 ± 6.09
全下半身缺失	31.81 ± 6.33	29.08 ± 4.91
随机关节丢失 30%	28.25 ± 9.56	28.23 ± 7.69
全下半身缺失	21.45 ± 3.07	20.66 ± 1.87

- **E15 当前运行验收：**结题报告/review_2026-10-07/cloud-workspace-validation.json、README.md，以及 pre-rep/results/deployment/workspace-validation.json。